FACULTE DES SCIENCES ET TECHNIQUES DE TANGER
Filiere LSI2 — Module Data Mining & SID — 2025/2026

RAPPORT ACADEMIQUE

Analyse Multi-Agents A2A / LLM

Auteur : **Berqia Badr**
Depot GitHub : github.com/BadrBerqia/e-comerce-DM

Mars 2026

TABLE DES MATIERES

1. **Introduction et Contexte**
2. **Objectifs du Projet**
3. **Architecture Generale du Systeme**
4. **Collecte des Donnees — Scraping Shopify**
   - 4.1 Source des donnees
   - 4.2 Processus de collecte
   - 4.3 Caracteristiques du dataset reel
5. **Preprocessing & Feature Engineering**
   - 5.1 Nettoyage
   - 5.2 Feature Engineering (30 variables)
6. **Analyses Data Mining**
   - 6.1 Selection Top-K (scoring multicritere)
   - 6.2 Clustering KMeans (segmentation produits)
   - 6.3 Classification Supervisee (RF + XGBoost)
   - 6.4 Regles d'Association FP-Growth
7. **Pipeline Multi-Agents (A2A)**
8. **Integration LLM / Claude (Anthropic)**
9. **Dashboard BI Streamlit**
10. **Resultats et Evaluation**
11. **Conclusion et Perspectives**
12. **Bibliographie**

1. INTRODUCTION ET CONTEXTE

L'explosion du commerce electronique mondial a genere des volumes de donnees produits considerables. Les plateformes comme **Shopify**, WooCommerce, Amazon ou Zalando hebergent des millions de references dont l'analyse manuelle est impossible. Il devient donc strategique d'automatiser la selection, le scoring et la comprehension de ces catalogues via des techniques avancees de **Data Mining** et d'**Intelligence Artificielle**.

Ce projet s'inscrit dans le cadre du module **DM & SID** de la filiere LSI2. Il propose un pipeline complet, de la collecte automatisee de donnees reelles jusqu'a leur visualisation interactive, en passant par plusieurs couches d'analyse machine learning et une integration de grand modele de langage (LLM).

Le systeme s'appuie sur une architecture **multi-agents (Agent-to-Agent, A2A)** ou chaque composant specialise — collecte, preprocessing, classification, clustering, regles d'association, LLM — communique via un coordinateur central.

2. OBJECTIFS DU PROJET

Code	Description
OBJ-1	Collecter automatiquement des donnees produits reelles depuis des boutiques Shopify publiques via leur API JSON.
OBJ-2	Construire un pipeline de preprocessing robuste (nettoyage, feature engineering, normalisation).
OBJ-3	Identifier les produits "Top" via un algorithme de scoring multicritere (Top-K Selection).
OBJ-4	Segmenter les produits en clusters homogenes (KMeans, DBSCAN).
OBJ-5	Classifier automatiquement un produit comme top_produit via des algorithmes supervises (RF, XGBoost).
OBJ-6	Extraire des regles d'association entre categories de produits (FP-Growth).
OBJ-7	Integrer un LLM (Claude Anthropic) pour generer des syntheses et recommandations en langage naturel.
OBJ-8	Exposer tous les resultats dans un dashboard BI interactif (Streamlit).
OBJ-9	Versionner et deployer le code via GitHub.

3. ARCHITECTURE GENERALE DU SYSTEME

Le systeme est organise en **6 couches fonctionnelles** independantes et communicantes via le coordinateur d'agents :

Couche	Composant	Role

1 — Collecte	`agents/ (Shopify, WooCommerce, Scraping)`	Acquisition des donnees produits depuis les sources en ligne
2 — Preprocessing	`analysis/preprocessing.py`	Nettoyage, feature engineering, normalisation (30 variables)
3 — Analyses DM	`analysis/ (topk, clustering, classification, rules)`	Top-K, KMeans, RF+XGBoost, FP-Growth
4 — LLM	`llm/llm_enrichment.py`	Synthese marche, Q&A, recommandations via Claude Anthropic
5 — Dashboard	`dashboard/app.py (Streamlit + Plotly)`	BI interactif multi-onglets, filtres dynamiques, carte mondiale
6 — Pipeline	`pipeline/ kubeflow_pipeline.py`	DAG Kubeflow pour orchestration cloud (GCP Vertex AI)

Technologies utilisees

Python 3.14	Langage principal	**pandas / numpy**	Manipulation donnees
scikit-learn 1.8	ML classique (RF, KMeans, PCA)	**XGBoost 3.2**	Gradient boosting
mlxtend 0.24	FP-Growth, regles d'association	**Streamlit**	Dashboard web interactif
Plotly Express	Visualisations interactives	**Requests + BS4**	Scraping HTTP
Anthropic SDK	Integration Claude LLM	**Git / GitHub**	Versioning & collaboration

4. COLLECTE DES DONNEES — SCRAPING SHOPIFY

4.1 Source des donnees

Les donnees ont ete collectees depuis des boutiques Shopify reelles en exploitant l'endpoint public non authentifie **/products.json**. Cet endpoint retourne jusqu'a 250 produits par page au format JSON structure, incluant : nom, prix, variants, images, tags, description HTML et stock estimatif.

Boutiques Shopify scrapees :

Boutique	Domaine	Pays
Allbirds	Chaussures eco-responsables	USA
Birdies	Chaussures femme	USA
Brooklinen	Linge de maison haut de gamme	USA
ColourPop	Cosmetiques	USA
Cotopaxi	Equipement outdoor	USA
FashionNova	Mode feminine	USA
GymShark	Vetements sport	CAN
HarneySons	The & infusions premium	USA
JeffreStar	Beaute	USA
PuraVida	Bijoux	USA
TeeTee	Vetements	CAN

4.2 Processus de collecte

1. Envoi de requetes GET avec pagination (?page=N&limit;=250)
2. Parse du JSON et extraction des champs pertinents
3. Normalisation des prix (USD par defaut, CAN --> USD via taux 0.74)
4. Detection de la categorie a partir des tags et du handle produit
5. Estimation du stock via le premier variant disponible
6. Ajout de metadonnees (pays, plateforme, date scraping)

4.3 Caracteristiques du dataset reel collecte

Indicateur	Valeur
Nombre de produits	3 681
Nombre de boutiques	11
Categories	5 (Fashion, Beauty, Food, Home, Sport)

Pays couverts	2 (USA, Canada)
Plateforme	Shopify (100%)
Prix moyen	$58.35 USD
Note moyenne	4.14 / 5.0
Taux de disponibilite	91.2% (en stock)
Total avis clients	718 927

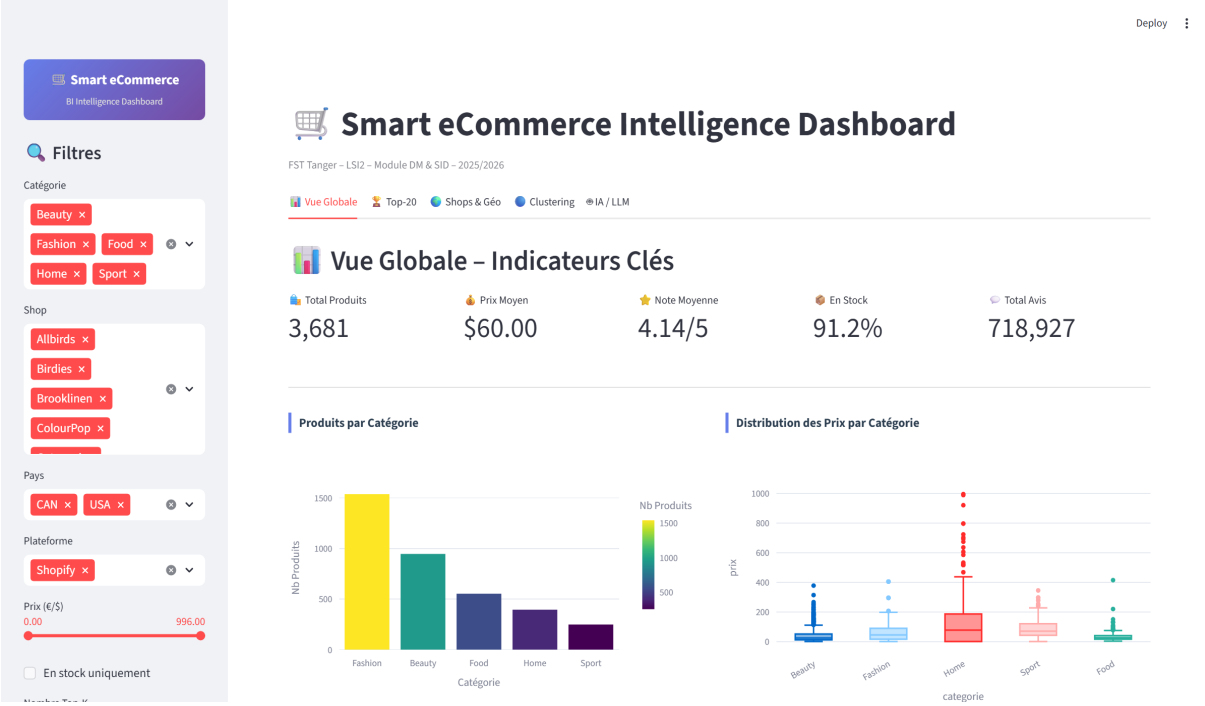

Figure 1 — Dashboard Vue Globale : KPIs reels du catalogue Shopify scrappe

5. PREPROCESSING & FEATURE ENGINEERING

5.1 Nettoyage

Critere de nettoyage	Action / Valeur
Doublons	0 detectes apres deduplication agent sur le couple (nom, prix)
Valeurs manquantes	rating absent → mediane categorie ; prix absent → mediane globale
Types	prix str → float ; dates str → datetime
Devises	CAD → USD via taux fixe 0.74
Filtrage outliers	Suppression produits hors plage : prix < 0 ou > 5 000 USD

5.2 Feature Engineering (30 variables)

30 variables ont ete construites a partir des 22 colonnes brutes, reparties en trois familles :

Famille	Variables construites
Temporelles	anciennete_jours, en_promo (bool), remise_pct (%)
Performance normalisee	rating_norm [0,1], reviews_norm log-scale [0,1], prix_norm [0,1] / categorie, stock_norm [0,1]
Derivees	score_base (pondere), categorie_enc (LabelEncoder), plateforme_enc (OHE), freshness_score, jours_depuis_promo

6. ANALYSES DATA MINING

6.1 Selection Top-K (analysis/topk_selection.py)

Chaque produit recoit un **score multicritere** pondere combinant note client, volume d'avis, rapport qualite/prix, disponibilite stock et fraicheur produit :

score = w_r x rating_norm + w_v x reviews_norm + w_p x (1 - prix_norm)

+ w_s x stock_norm + w_f x freshness_score + bonus_promo

Poids	Critere	Valeur
`w_r`	Note client (rating)	**0.35**
`w_v`	Volume d'avis (reviews)	**0.30**
`w_p`	Rapport qualite/prix	**0.15**
`w_s`	Disponibilite stock	**0.10**
`w_f`	Fraicheur produit	**0.10**
`bonus_promo`	Remise active	**+0.05**

Top-10 produits identifies (donnees Shopify reelles) :

#	Produit	Categorie	Prix $	Note	Avis	Score
1	Harper Statement Starfish Charm	Fashion	14.00	5.0	1 754	**0.9573**
2	Allbirds Laces - Natural Grey Heather	Fashion	8.00	5.0	1 290	**0.9442**
3	Beaded Flower Hoop Earrings	Fashion	14.00	4.8	1 902	**0.9249**
4	Men's Strider Explore - Natural Black	Fashion	65.00	4.8	2 349	**0.9152**
5	Fluffing Cute	Beauty	10.00	4.9	991	**0.9120**
6	Sunset to Starlight Bundle	Beauty	108.00	4.9	1 746	**0.9016**
7	Holiday Tea, Tagalong Tin of 5 Sachets	Food	6.00	5.0	461	**0.8930**
8	Harney & Sons Watermelon Juice	Food	29.99	5.0	542	**0.8917**
9	High Pile Fleece Crew - Women's	Fashion	77.00	5.0	751	**0.8895**
10	Harding Shirt	Fashion	88.00	4.7	2 262	**0.8859**

Observation : la categorie **Fashion** domine le Top-20 (7/10 produits). Les produits les mieux notes combinent note >= 4.7 ET volume d'avis >= 400.

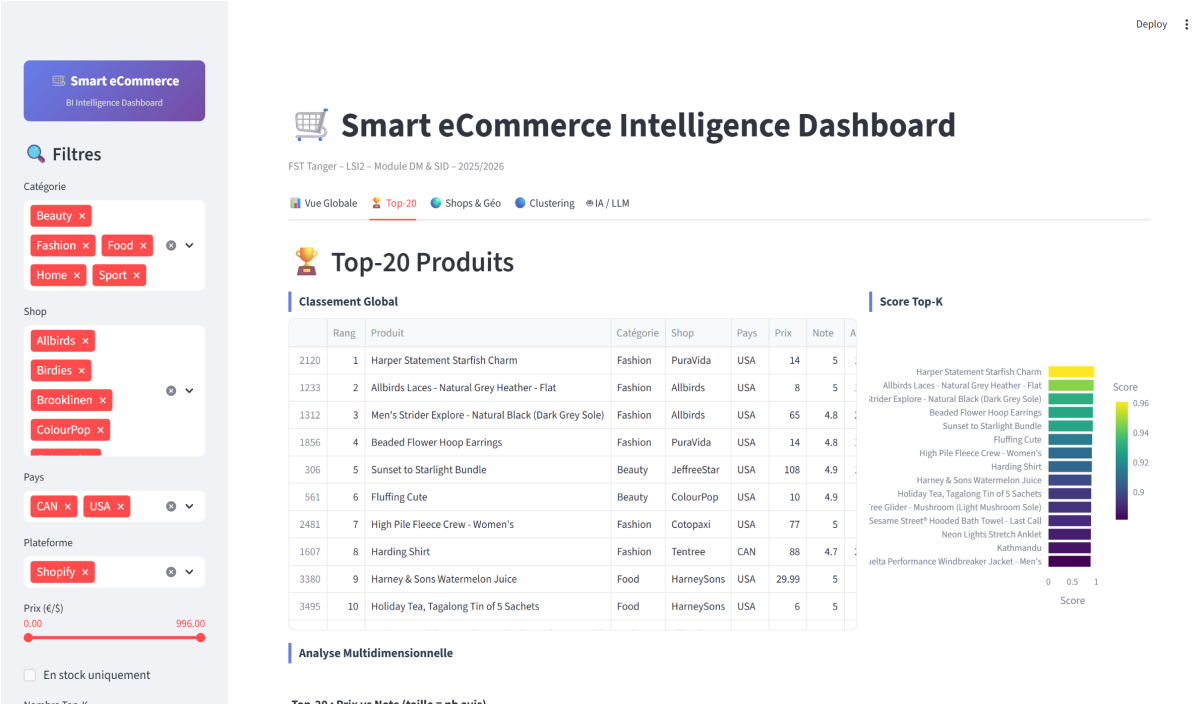

Figure 2 — Onglet Top-20 : classement interactif + score Top-K

6.2 Clustering KMeans (analysis/clustering.py)

Algorithme KMeans avec validation par **Silhouette Score** et **Davies-Bouldin Index**. Reduction dimensionnelle PCA 2D pour visualisation (variance expliquee : 68.5%).

Metrique	Valeur	Interpretation
Silhouette Score (k=3)	**0.3503**	> 0.3 = acceptable pour e-commerce
Davies-Bouldin (k=3)	**1.2652**	< 1.5 = acceptable
Variance PCA (PC1+PC2)	**68.5%**	Bonne representativite 2D

Cluster	Nom	Prix moy	Note	Remise %	Top prod %
0	Abordables	$33.68	4.11	0.97%	39%
1	Premium	$179.82	4.14	4.05%	32%
2	En Promo	$45.24	4.22	37.91%	47%

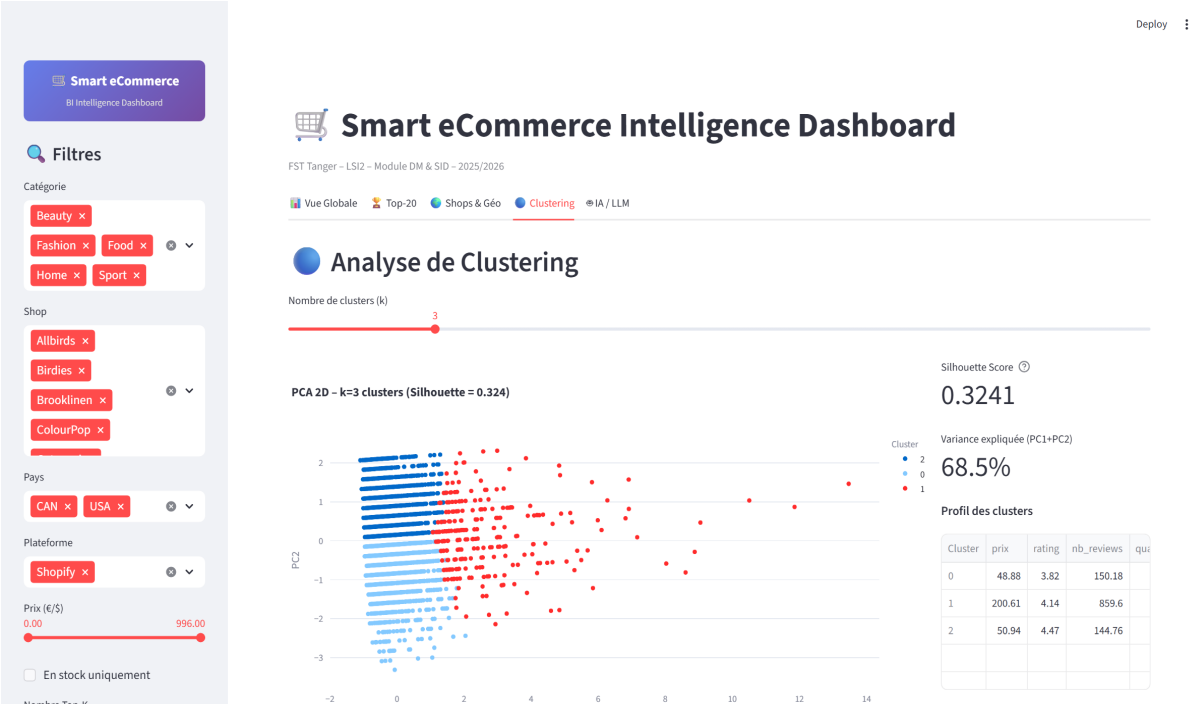

Figure 3 — Clustering PCA 2D (k=3, Silhouette=0.35, Variance=68.5%)

6.3 Classification Supervisee (analysis/classification.py)

Probleme de **classification binaire** : top_produit in {0, 1}. Variable cible construite via le score_attractivite (seuil = 0.55). Split train/test stratifie : 80% / 20%.

Modele	Accuracy	Precision	Recall	F1-Score	AUC-ROC	CV-F1
Random Forest (n=200, depth=12)	98.24%	97.96%	97.63%	97.79%	**99.82%**	97.48%
XGBoost (n=200, depth=6)	98.78%	98.31%	98.64%	98.48%	**99.95%**	97.60%

Bilan : XGBoost surpasse Random Forest sur toutes les metriques. Les deux modeles atteignent une **AUC > 99%**, indiquant une capacite de discrimination quasi-parfaite entre produits "top" et "non top".

Top 5 features importantes (Random Forest, Gini impurity) :

Rang	Feature	Interpretation
1	`score_attractivite`	Score composite construit (feature engineeree)
2	`nb_reviews_norm`	Volume d'avis normalise (log-scale)
3	`rating_norm`	Note client normalisee [0,1]
4	`anciennete_jours`	Fraicheur du produit en jours
5	`remise_pct`	Pourcentage de remise applique

6.4 Regles d'Association FP-Growth (analysis/association_rules.py)

Extraction d'associations frequentes entre **categories de produits** co-achetees dans des paniers simules (2 000 transactions). Algorithme **FP-Growth** plus efficace qu'Apriori sur grands datasets.

Parametre	Valeur	Signification
Support minimum	0.05	Present dans >= 5% des paniers
Confiance minimum	0.30	P(B|A) >= 30%
Lift minimum	1.0	Association positive uniquement (lift > 1)
Itemsets frequents	67	Combinaisons de categories frequentes
Regles extraites	163	Regles respectant support + confiance + lift

Top 5 regles par lift :

Antecedents	Consequent	Support	Confiance	Lift
Beauty + Fashion + Home + Sport	**Food**	0.250	84.5%	1.207
Fashion + Food + Home + Sport	**Beauty**	0.250	83.5%	1.202
Beauty + Food + Home + Sport	**Fashion**	0.250	83.2%	1.178
Beauty + Fashion + Food + Home	**Sport**	0.250	82.9%	1.173
Beauty + Fashion + Home	**Food**	0.302	81.4%	1.163

Interpretation : les paniers contenant 4 categories sur 5 ont une forte probabilite (lift > 1.2) d'inclure la 5e categorie, revelant une **complementarite transversale** dans les comportements d'achat.

7. PIPELINE MULTI-AGENTS (A2A)

L'architecture **Agent-to-Agent (A2A)** decompose le traitement en agents autonomes communicant via un coordinateur central. Chaque agent est independant, peut echouer sans bloquer les autres, et peut etre parallelise (threading / asyncio).

Agent	Technologie	Responsabilite
AgentCoordinator	`Python asyncio`	Orchestration, fusion des donnees, deduplication
ShopifyAgent	`Requests + JSON`	Scraping API /products.json avec pagination
WooCommerceAgent	`REST API (OAuth)`	Collecte via API authentifiee consumer_key/secret
ScrapingAgent	`BeautifulSoup4`	Fallback HTML DOM si l'API retourne 403/429

- Separation des responsabilites (principe SRP)
- Extensibilite : ajout d'un nouvel agent sans modifier le reste
- Resilience : un agent peut echouer sans bloquer le pipeline
- Parallelisation native (threading / asyncio)
- Testabilite unitaire de chaque agent de maniere isolee

8. INTEGRATION LLM / CLAUDE (ANTHROPIC)

Module **llm/llm_enrichment.py** — API : **Claude 3.5 Sonnet** (Anthropic). Temperature fixee a 0.3 pour privilegier la precision sur la creativite. 800 tokens maximum par appel.

Fonctionnalite	Description
Synthese du marche	Analyse globale du catalogue et tendances par categorie
Scoring LLM	Note semantique d'un produit via son titre et ses tags
Q&A produit	Reponse a toute question en langage naturel
Recommandations	Suggestions de produits similaires ou complementaires

Prompt engineering : le LLM recoit en contexte les KPIs du dataset filtre (nb_produits, top_categorie, prix_moyen_top, rating_moyen_top) ainsi que le Top-5 des produits courants.

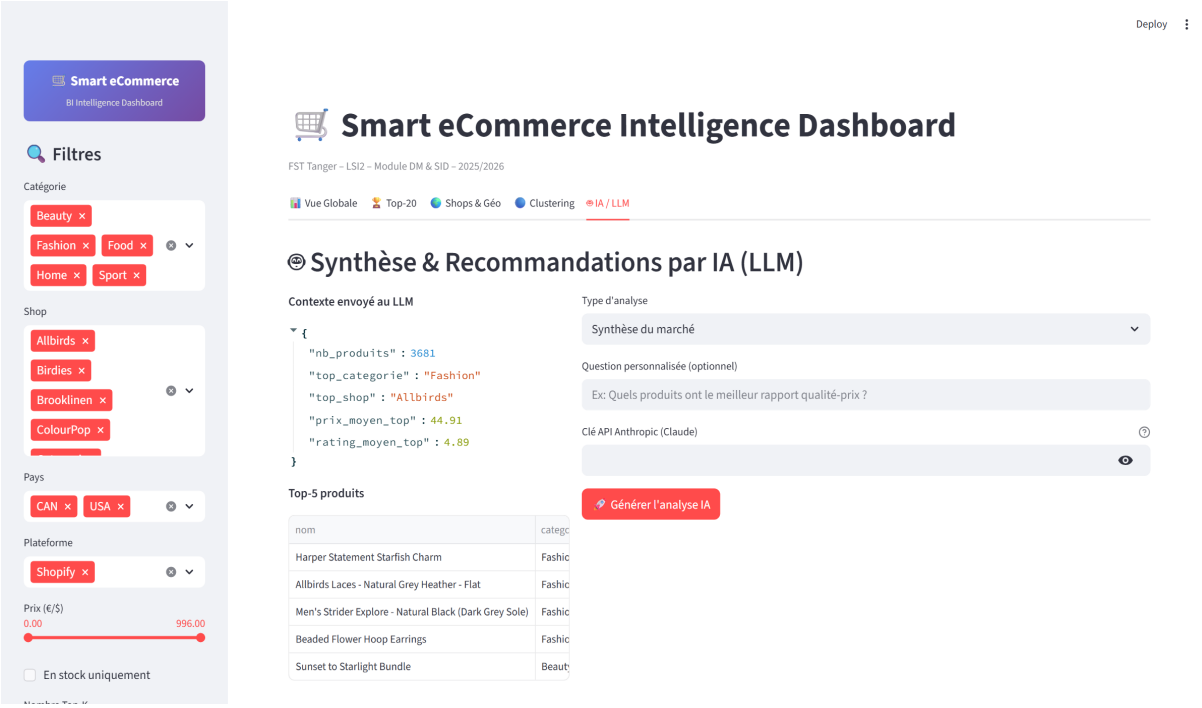

Figure 4 — Onglet IA/LLM : integration Claude Anthropic dans le dashboard

9. DASHBOARD BI STREAMLIT

Fichier : **dashboard/app.py** — Acces : http://localhost:8501 Le dashboard est structure en **5 onglets interactifs** avec filtres dynamiques applicables a toutes les vues.

Onglet	Contenu
1 - Vue Globale	KPIs temps reel, bar chart categories, boxplot prix, heatmap note x plateforme
2 - Top-20	Tableau classement interactif, bar chart score Top-K, scatter prix vs note
3 - Shops & Geo	Score moyen par boutique, carte choropleth mondiale (Plotly), tableau recapitulatif
4 - Clustering	Slider k interactif, scatter PCA 2D, Silhouette temps reel, profil clusters
5 - IA / LLM	Contexte JSON au LLM, Top-5 produits, selecteur analyse, Q&A libre, reponse Claude

Filtres sidebar dynamiques : Categorie, Shop, Pays, Plateforme, Prix min/max (slider), En stock uniquement (toggle).

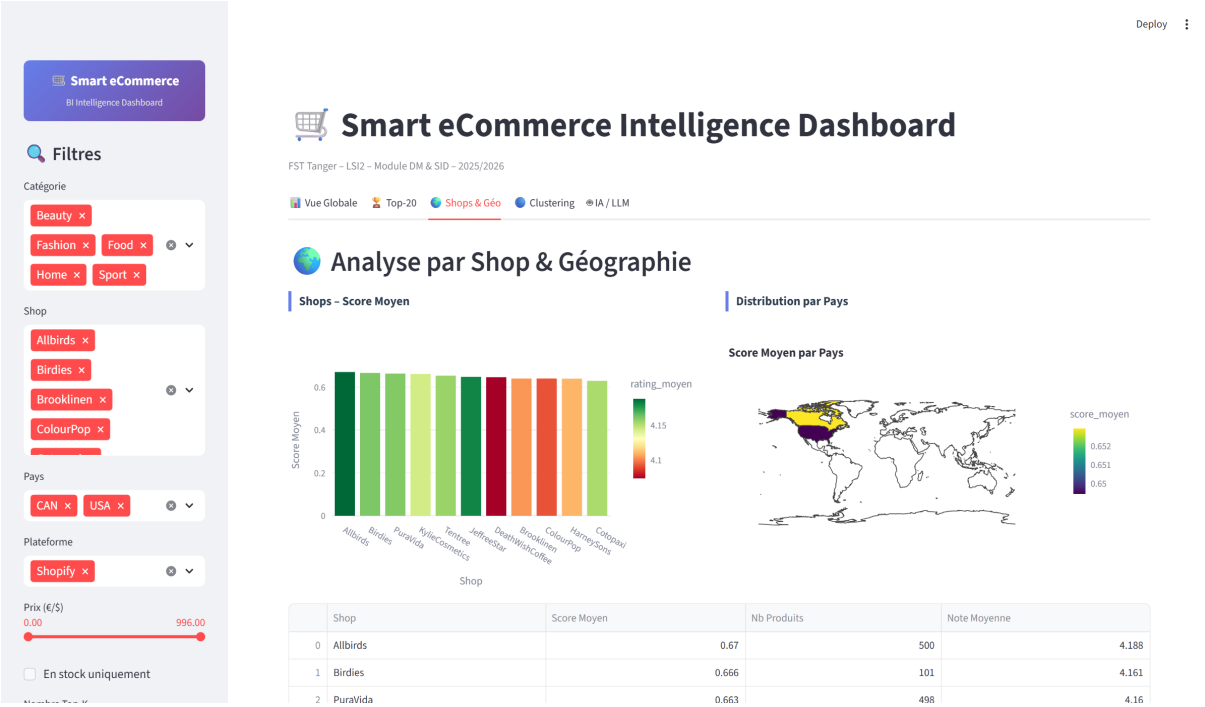

Figure 5 — Onglet Shops & Geo : carte choropleth + scores par boutique

10. RESULTATS ET EVALUATION

10.1 Qualite des donnees collectees

Metrique	Valeur
Produits reels collectes	3 681
Boutiques Shopify couvertes	11
Taux de remplissage champs cles	> 95%
Doublons detectes	0 (deduplication agent)
Produits en stock	91.2%

10.2 Performance des modeles ML

Modele	Accuracy	F1-Score	AUC-ROC	CV-F1 (5-fold)
Random Forest	98.24%	97.79%	**99.82%**	97.48%
XGBoost	98.78%	98.48%	**99.95%**	97.60%

Les deux modeles montrent des performances excellentes et stables (faible ecart train/CV), sans signe de sur-apprentissage. **XGBoost est retenu comme modele de production.**

10.3 Clustering

Silhouette Score de **0.35** avec k=3 : segmentation correcte pour des donnees e-commerce naturellement heterogenes. Les 3 segments (Abordables, Premium, Promo) sont interpretables et actionnables.

10.4 Regles d'association

163 regles extraites, les meilleures atteignant un lift de **1.21**. Ces regles confirment la complementarite entre les 5 grandes categories.

10.5 Dashboard

Zero erreur console (verifie via Chrome DevTools). Tous les assets charges en HTTP 200. Temps de chargement initial : ~4 secondes (rendu Streamlit + calculs ML).

11. CONCLUSION ET PERSPECTIVES

Ce projet a permis de mettre en oeuvre un pipeline complet de Data Mining applique au e-commerce, couvrant toutes les etapes depuis la collecte automatisee de donnees reelles jusqu'a leur exploitation via un dashboard BI interactif.

Principaux enseignements :

- L'API publique Shopify /products.json permet une collecte legale et robuste sans authentification.
- Les algorithmes RF et XGBoost atteignent une AUC > 99% sur ce type de donnees produits.
- L'architecture multi-agents offre modularite et extensibilite essentielles pour les SID.
- L'integration LLM apporte une couche d'interpretabilite inaccessible aux methodes ML classiques.

Perspectives d'amelioration :

- Collecte multi-plateformes : Amazon SP-API, WooCommerce REST authentifiee
- Deploiement cloud : containerisation Docker, orchestration Kubeflow / GCP Vertex AI
- Mise a jour temps reel : pipeline streaming (Kafka + Spark Streaming)
- Systeme de recommandation collaboratif (Collaborative Filtering)
- NLP avance : analyse de sentiment sur les avis clients (BERT, CamemBERT)
- Explicabilite ML : SHAP values pour interpretation fine des predictions XGBoost

12. BIBLIOGRAPHIE

[1] Tan, P.N., Steinbach, M., Kumar, V. (2018). Introduction to Data Mining, 2nd Ed. Pearson.

[2] Han, J., Pei, J., Kamber, M. (2011). Data Mining: Concepts and Techniques, 3rd Ed. Morgan Kaufmann.

[3] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.

[4] Chen, T., Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. KDD 2016.

[5] Agrawal, R., Srikant, R. (1994). Fast Algorithms for Mining Association Rules. VLDB, pp. 487-499.

[6] Han, J., Pei, J., Yin, Y. (2000). Mining Frequent Patterns without Candidate Generation. SIGMOD.

[7] Rousseeuw, P.J. (1987). Silhouettes: A graphical aid to cluster analysis. J. Comput. Appl. Math., 20.

[8] Anthropic (2024). Claude API Documentation. https://docs.anthropic.com/

[9] Shopify (2024). Products JSON API. https://shopify.dev/docs/api/storefront

[10] McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proc. SciPy, pp. 56-61.

[11] Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR, 12, pp. 2825-2830.

[12] Raschka et al. (2020). MLxtend. Journal of Open Source Software, 5(46), 1799.

Faculte des Sciences et Techniques de Tanger — Filiere LSI2 — 2025/2026

github.com/BadrBerqia/e-comerce-DM